

THÉORIE DES LANGAGES : ANALYSE LEXICALE – PARTIE 2

L3 INFORMATIQUE – 2020/21

Eric Andres
eric.andres@univ-poitiers.fr



LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Def : Σ un alphabet, on appelle **classe des langages rationnels** $\text{Rat}(\Sigma)$ l'ensemble des langages vérifiant :
 - Tout sous-ensemble fini de Σ^* est dans $\text{Rat}(\Sigma)$
 - Pour $L_1 \in \text{Rat}(\Sigma)$ et $L_2 \in \text{Rat}(\Sigma)$ alors
 - $L_1 \cup L_2 \in \text{Rat}(\Sigma)$
 - $L_1 \bullet L_2 \in \text{Rat}(\Sigma)$
 - $L_1^* \in \text{Rat}(\Sigma)$ (et bien sûr L_2^* aussi)
 - $\text{Rat}(\Sigma)$ est le plus petit ensemble de langages possibles vérifiant cela.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Def : **Expression régulière**

La définition d'un langage rationnel en

- Un ensemble fini de mots (y compris)
- Concaténation
- Union
- Etoile

Et donc nécessairement fini. Une telle expression s'appelle « **expression régulière** »

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

Propriété : Un langage est rationnel ssi il existe une expression rationnelle le définissant

exemple :

- **ab^*** : attention, c'est un abus : on devrait écrire **$\{a\}.\{b\}^*$** = {a, ab, abb, abbb, ...}
- **$(ab)^*$** = { ϵ , ab, abab, ababab, ... }
- **$a+ba^*$** = $\{a\} \cup \{b\}\{a\}^*$ = {a, b, ba, baa, baaa, ...}

$aa^* = a^+$: Deux expressions rationnelles peuvent être différentes et représenter le même langage !

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

Propriété :

- Si $L \in \text{Rat}(\Sigma)$ et si $R: \Sigma^* \rightarrow \Pi^*$ est un morphisme de monoïde alors $R(L) \in \text{Rat}(\Pi)$
- L'image miroir d'un langage rationnel est aussi rationnel (on verra la preuve en TD)

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

Propriété : **Lemme de l'étoile**

Soit L un langage rationnel, alors il existe un entier k tel que :

- $\forall u \in L, \text{ tq } |u| > k, \text{ il existe trois mots } v, w \text{ et } z \text{ tel que :}$
 - $u = v \bullet w \bullet z$
 - $w \neq \varepsilon$
 - $v \bullet w^* \bullet z \in L$

Le lemme de l'étoile est couramment utilisé pour montrer qu'un langage donné n'est pas rationnel (en raisonnant par l'absurde). En revanche, il ne peut être employé pour démontrer qu'un langage est rationnel. En effet, il énonce une condition, nécessaire certes, mais non suffisante, de rationalité

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Exemple : $L = \{a^n b^n : n \in \mathbb{N}\}$ est-il rationnel ?


Parfois c'est plus compliqué : le langage de tous les palindromes n'est pas rationnel mais on peut toujours trouver un découpage $v \bullet w \bullet z$ qui respecte toutes les conditions.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES


- Def : On appelle **automate fini** un quintuplet (Σ, Q, I, T, d) où
 - Σ est un alphabet fini
 - $Q \subset \mathbb{N}$ est un ensemble fini d'états
 - $I \in Q$ est l'état initial (en général un seul)
 - $T \subset Q$ est l'ensemble des états terminaux
 - $d \subset Q \times S \times Q$ est l'ensemble des transitions

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Image pour les automates :



Exemple d'automate fini : les mots commençant par a sur $\Sigma = \{a, b\}$




LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Def :
 - **Automate Complet** : de chaque état part une transition pour chaque lettre de l'alphabet
 - **Automate Déterministe** : si pour chaque état il n'existe qu'une seule transition possible (et pas de transition en ε)
 - **Automate Monogène** : Chaque état est atteignable (depuis l'état initial)


LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Exemple :



Complet, déterministe mais pas monogène.

$$L = (a+b)(a+b)(a+b)^*$$



Pas déterministe

$$L = \{aa, ab\} = a(a+b)$$

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Def : On appelle **chemin** dans un automate toute suite d'états partant d'un état i et atteignant un état j .
- Def : Un chemin **valide** va de l'état initial à un état final.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Def : A chaque chemin correspond un mot (par les lettres des transitions). Un **mot reconnu** est un mot d'un chemin valide.
- Def : On appelle **langage accepté/reconnu** par un automate A l'ensemble des mots reconnus de A : noté $L(A)$

Notez que pour les automates non déterministes, il peut y avoir plusieurs chemins correspondant au même mot. Le mot sera reconnu si au moins un des chemins correspondant à ce mot est un chemin valide.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Def : Soit Σ un alphabet et $L \subset \Sigma^*$, alors L est un **langage reconnaissable** ssi il existe un automate fini sur Σ tel que $L=L(A)$

L'ensemble des langages reconnaissables est noté **Rec(Σ)**

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Proposition :

- $L1 \bullet L2 \in \text{Rec}(\Sigma)$
- $L1 \cup L2 \in \text{Rec}(\Sigma)$
- $L1 \cap L2 \in \text{Rec}(\Sigma)$
- $\Sigma^* - L1 \in \text{Rec}(\Sigma)$
- $L1^* \in \text{Rec}(\Sigma)$

Le complémentaire

Preuve : Il suffit pour chaque cas d'appliquer la définition, i.e. trouver un automate qui reconnaît le langage considéré.

Corollaire : Les reconnaissables sont fermés par \cup , \bullet et $*$ donc $\text{Rat}(\Sigma) \subset \text{Rec}(\Sigma)$

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES


- Proposition :

- $L1 \bullet L2 \in \text{Rec}(\Sigma)$
- $L1 \cup L2 \in \text{Rec}(\Sigma)$
- $L1 \cap L2 \in \text{Rec}(\Sigma)$
- $\Sigma^* - L1 \in \text{Rec}(\Sigma)$
- $L1^* \in \text{Rec}(\Sigma)$

Preuve : Il suffit pour chaque cas d'appliquer la définition, i.e. trouver un automate qui reconnaît le langage considéré.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Concaténation



Nous verrons comment éliminer les transitions en ϵ . En particulier il faut faire un petit peu attention aux états terminaux

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- **Elimination des ε -transitions**


- Pour éliminer les ε -transitions, il faut comprendre qu'une ε -transition c'est comme se téléporter d'un état à un autre sans consommer de lettre. Pour les éliminer, on va calculer la ε -fermeture çàd qu'on va regarder à partir d'un état vers quels autres états on peut aller avec ε et appliquer l'algorithme de fermeture transitive.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Elimination des ε -transitions : Exemple : $A = \{\{a,b\}, \{0,1,2,3,4\}, 0, \{3,4\}, d\}$

d : table de transitions

	a	b	ε
0	1		2
1		2	4
2	3		4
3		0	
4	2	3	



ε -cloture pour chaque état

Etats	Atteints par ε
0	0, 2, 4
1	1, 4
2	2, 4
3	3
4	4

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES


- Elimination des ε -transitions :

	a	b	e
0	1		2
1		2	4
2	3		4
3		0	
4	2	3	

Etats	Atteints par ε
0	0, 2, 4
1	1, 4
2	2, 4
3	3
4	4

Exemple au tableau


Dernière partie : Si on a $s \xrightarrow{\varepsilon} t$ avec t état terminal alors s devient aussi terminal.




LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Elimination des ε -transitions :

	a	b	e
0	1		2
1		2	4
2	3		4
3		0	
4	2	3	



	a	b
0	1,2,3,4	3
1	2,4	2,3,4
2	2,3,4	3
3		0,2,4
4	2,4	3



LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES


- Proposition :

- $L1 \bullet L2 \in \text{Rec}(\Sigma)$
- $L1 \cup L2 \in \text{Rec}(\Sigma)$
- $L1 \cap L2 \in \text{Rec}(\Sigma)$
- $\Sigma^* - L1 \in \text{Rec}(\Sigma)$
- $L1^* \in \text{Rec}(\Sigma)$

Preuve : Il suffit pour chaque cas d'appliquer la définition, i.e. trouver un automate qui reconnaît le langage considéré.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Union



Si L'un des états initiaux I ou I' est terminal alors l'état 0 devient terminal

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES



- **Proposition :**

- $L1 \bullet L2 \in \text{Rec}(\Sigma)$
- $L1 \cup L2 \in \text{Rec}(\Sigma)$
- $L1 \cap L2 \in \text{Rec}(\Sigma)$
- $\Sigma^* - L1 \in \text{Rec}(\Sigma)$
- $L1^* \in \text{Rec}(\Sigma)$

Preuve : Il suffit pour chaque cas d'appliquer la définition, i.e. trouver un automate qui reconnaît le langage considéré.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Intersection



L'idée générale est la suivante : On avance en // sur les **deux automates complets et déterministes**. Si on stoppe en même temps sur un état terminal de chaque côté alors le mot est reconnu par les deux. **On verra comment ça marche pour la détermination.**

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Comment rendre un automate complet ? Ici $\Sigma = \{a,b\}$

Pour compléter un automate on crée un **PUIT** qui correspond à tous les chemins manquants




Table de Transition



	a	b
1	2	P
2	3	4
3	P	3
4	P	4
P	P	P

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Exemple d'Intersection : $\Sigma = \{a, b\}$
- Langage L1 = mots contenant aa = $(a+b)^* aa (a+b)^*$
- Langage L2 = mots se terminant par a = $(a+b)^* a$

A1

	a	b
1	2	1
2	3	1
3	3	3



A2

	a	b
A	B	A
B	B	A

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Exemple d'Intersection : $\Sigma = \{a, b\}$


A1

	a	b
1	2	1
2	3	1
3	3	3

A2

	a	b
A	B	A
2	B	A

	a	b
1A	2B	1A
2B	3B	1A
3B	3B	3A
3A	3B	3A



L'état terminal est un état terminal pour les 2 automates (pour l'intersection, un mot doit être reconnu par les 2) : ici 3 et B : **3B**

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- **Proposition :**


- $L1 \bullet L2 \in \text{Rec}(\Sigma)$
- $L1 \cup L2 \in \text{Rec}(\Sigma)$
- $L1 \cap L2 \in \text{Rec}(\Sigma)$
- $\Sigma^* - L1 \in \text{Rec}(\Sigma)$
- $L1^* \in \text{Rec}(\Sigma)$

Le complémentaire

Preuve : Il suffit pour chaque cas d'appliquer la définition, i.e. trouver un automate qui reconnaît le langage considéré.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Complémentaire



Il suffit de changer les états terminaux en non-terminaux et vice-versa


si l'automate est complet et déterministe

Le langage complémentaire de L se définit par $\Sigma^* - L$

Pour les expressions rationnelles, décrire le langage complémentaire peut être compliqué :

Ex: L = mots contenant aa sur $\Sigma=\{a,b\}$: $(a+b)^*aa(a+b)^*$

Ex: \bar{L} = mots sans facteur aa : $b^*a(b^+a)^*$: pas immédiat



LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES


- **Proposition :**

- $L1 \bullet L2 \in \text{Rec}(\Sigma)$
- $L1 \cup L2 \in \text{Rec}(\Sigma)$
- $L1 \cap L2 \in \text{Rec}(\Sigma)$
- $\Sigma^* - L1 \in \text{Rec}(\Sigma)$
- $L1^* \in \text{Rec}(\Sigma)$

Preuve : Il suffit pour chaque cas d'appliquer la définition, i.e. trouver un automate qui reconnaît le langage considéré.

LANGAGES RATIONNELS ET LANGAGES RECONNAISSABLES

- Passage à l'étoile



L'idée c'est de fusionner les états terminaux avec l'état initial pour pouvoir boucler sur l'automate et reconnaître un nouveau mot sur l'automate.

Evidemment, l'état initial devient terminal.